

## Peramalan Curah Hujan Menggunakan Metode *Extreme Learning Machine*

Rich Juniadi Domitri Simamora<sup>1</sup>, Tibyani<sup>2</sup>, Sutrisno<sup>3</sup>

Program Studi Teknik Informatika, Fakultas Ilmu Komputer, Universitas Brawijaya  
Email: <sup>1</sup>richjuniadi2@gmail.ac.id, <sup>2</sup>Tibyani@ub.ac.id, <sup>3</sup>trisno@ub.ac.id

### Abstrak

Curah hujan adalah ketinggian air hujan yang terdapat dan terkumpul di tempat yang datar, tidak meresap, tidak menguap dan tidak mengalir. Informasi mengenai curah hujan sangat penting terutama di bidang pertanian dan sipil. Pada bidang pertanian informasi curah hujan digunakan untuk menentukan jenis tanaman yang akan ditanam sesuai dengan intensitas curah hujan, memprediksi awal musim tanam dalam kalender tanam untuk meminimalisir resiko penanaman. Pada bidang sipil, digunakan sebagai penentu standar rancang keteknikan dalam melakukan perencanaan bangunan pengendalian bencana banjir. Curah hujan di atas normal akan menimbulkan masalah bencana alam seperti banjir dan tanah longsor. Curah hujan adalah bagian dari elemen cuaca dan salah satu proses meteorologi yang cukup sulit untuk diprediksi. Maka dari itu, diperlukan peramalan curah hujan agar masyarakat dan pemerintah dapat melakukan tindakan pencegahan terhadap masalah yang ada. Proses peramalan terbagi menjadi beberapa proses yang antara lain normalisasi data, peramalan dengan algoritme *Extreme Learning Machine*, denormalisasi data dan hasil *error* dengan MAPE. Berdasarkan hasil pengujian menggunakan data curah hujan daerah Poncokusumo dengan rentang waktu tahun 2002 sampai 2015 diperoleh nilai MAPE terkecil sebesar 3.6852 %, dengan banyak fitur sebanyak 4, banyak *neuron* pada *hidden layer* sebanyak 2, persentase data *training* 80%.

**Kata kunci:** peramalan, curah hujan, *Extreme Learning Machine*, MAPE

### Abstract

Rainfall is the height of rain water that is found and collected in a flat, not absorbed, does not evaporate and does not flow. Information about rainfall is very important especially in agriculture and civil. In agriculture, rainfall information is used to determine the type of plants to be planted in accordance with the intensity of rainfall, predicting the start of the growing season in the planting calendar to minimize the risk of planting. In the civil field, it is used as a determinant of engineering design standards in planning flood disaster control buildings. Above normal rainfall will cause natural disasters such as floods and landslides. Rainfall is part of the weather element and one of the meteorological processes that is quite difficult to predict. Rainfall forecasting is needed so that the community and the government can take preventative measures against the existing problems. The forecasting process is divided into several processes which include data normalization, forecasting with the *Extreme Learning Machine* algorithm, data denormalization and the results of errors with MAPE. Based on the test results using rainfall data in the Poncokusumo area with a span of years 2002 to 2015 obtained the smallest MAPE value of 3.6852%, with as many features as 4, many neurons in the hidden layer as much as 2, the percentage of training data 90%.

**Keywords:** forecasting, rainfall, *Extreme Learning Machine*, MAPE

## 1. PENDAHULUAN

Indonesia adalah negara kepulauan yang berada di daerah iklim tropis dan rentan terhadap perubahan iklim. Perubahan iklim ini mengakibatkan terjadinya perubahan intensitas hujan dengan tidak menentu yang dipengaruhi

oleh curah hujan. Curah hujan di atas normal akan menimbulkan masalah bencana alam seperti banjir dan tanah longsor.

Curah hujan adalah ketinggian air hujan yang terdapat dan terkumpul di tempat yang datar, tidak meresap, tidak menguap dan tidak mengalir (Ogi, 2011). Curah hujan adalah

bagian dari elemen cuaca dan salah satu proses meteorologi yang sulit untuk diprediksi (Jimoh, 2013). Melalui curah hujan dapat digunakan untuk menentukan suatu sifat hujan, intensitas dan normal curah hujan (BMKG, 2015).

Informasi mengenai curah hujan sangat penting terutama di bidang pertanian dan sipil. Pada bidang pertanian informasi curah hujan digunakan untuk menentukan jenis tanaman yang akan ditanam sesuai dengan intensitas curah hujan (Rani, K. B., & Govardhan, 2013), memprediksi awal musim tanam dalam kalender tanam untuk meminimalisir resiko penanaman (Nhita, 2015). Pada pertanian kentang di wilayah Tengger dengan perubahan curah hujan yang tidak tentu menjadi suatu kendala karena memiliki dampak buruk pada produktivitas kentang (Wahyuni, 2016). Di bidang sipil, sebagai penentu standar rancang keteknikan di dalam melakukan perencanaan bangunan pengendalian bencana banjir (Kusumawati & Sulistiowati, 2010). Pentingnya faktor curah hujan tersebut membuat para peneliti mengembangkan metode-metode dalam melakukan prediksi curah hujan dengan tingkat akurasi yang tinggi (Toth, 2005).

Penelitian sebelumnya melakukan perbandingan hasil peramalan permintaan data produksi kaos dan pin dengan metode *Extreme Learning Machine* (ELM) dengan *Moving Average* (MA) dan *Exponential Smoothing* (ES). Pada penelitian tersebut menunjukkan bahwa metode ELM menghasilkan peramalan dengan tingkat kesalahan *Mean Absolute Percentage Error* (MAPE) yang rendah jika dibandingkan dengan metode ES dan MA (Agustina, 2009), selain itu ELM juga memiliki *learning speed* yang relatif singkat (Agustina, 2009).

Khotimah (2010) melakukan penelitian dengan membandingkan kinerja dari metode Jaringan Saraf Tiruan (JST) yaitu ELM dan *Backpropagation*. Pada penelitian tersebut dilakukan uji coba pelatihan dan pengujian dengan melakukan konfigurasi pada parameter *hidden layer* dan jumlah *epoch*. Berdasarkan penelitian tersebut diperoleh nilai kesalahan *Mean Square Error* (MSE) dan *Mean Absolute Percentage Error* (MAPE) dengan metode ELM lebih kecil dibandingkan dengan metode *Backpropagation* (Khotimah, 2010).

Berdasarkan penelitian yang telah dilakukan sebelumnya, diharapkan nantinya penelitian ini akan memperoleh tingkat akurasi yang lebih baik dalam melakukan peramalan

curah hujan dengan metode *Extreme Learning Machine* (ELM).

## 2. DASAR TEORI

### 2.1. Peramalan

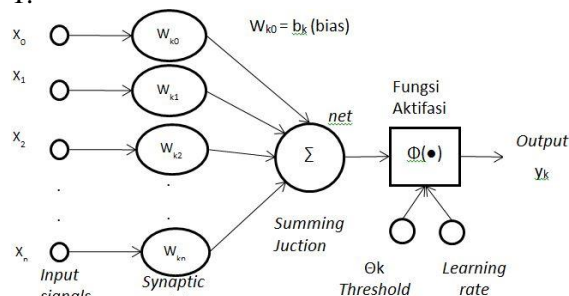
Peramalan adalah suatu proses dalam memperkirakan suatu objek atau kebutuhan di masa akan datang yang meliputi kebutuhan dalam ukuran kuantitas, kualitas, waktu, dan lokasi yang dibutuhkan untuk memenuhi kebutuhan informasi (Nhita, 2015).

### 2.2. Curah Hujan

Curah hujan adalah jumlah dari ketinggian air hujan yang terkumpul dan terdapat di tempat yang datar, tidak mengalir, tidak meresap, dan tidak menguap (Kusumastuti, 2015). Hujan merupakan partikel hydrometeor yang jatuh dalam bentuk air yang mempunyai diameter 0,5 mm atau lebih. Hujan yang jatuh ke permukaan tanah dapat diukur berdasarkan tinggi air hujan dan dengan melalui volume air hujan per satuan luas, kemudian dari hasil pengukuran tersebut dihasilkan dengan nama curah hujan (Kusumastuti, 2015).

### 2.3. Jaringan Saraf Tiruan (JST)

JST merupakan suatu metode pengolahan informasi yang terinspirasi berdasarkan cara kerja sistem saraf secara biologis seperti proses informasi pada otak manusia. Hal penting dari metode ini adalah struktur dari sistem pengolahan informasi yang terdiri dari sejumlah besar elemen pemrosesan yang saling berhubungan (*neuron*), bekerja serentak untuk menyelesaikan suatu masalah tertentu (Fardani, 2015). Model matematis dari arsitektur Jaringan Saraf Tiruan ditunjukkan pada Gambar 1.



Gambar 1. Arsitektur Jaringan Saraf Tiruan

### 2.4. Fungsi Aktivasi

Sifat dari Jaringan Saraf Tiruan ditentukan

oleh bobot (*weght*) dan *input-output* fungsi aktivasi yang telah ditentukan sebelumnya. Pada penelitian ini fungsi yang digunakan adalah fungsi *sigmoid biner* karena fungsi aktivasi ini memperoleh nilai error paling kecil dibandingkan dengan fungsi aktivasi lainnya (Cao et al., 2017). fungsi sigmoid biner ditunjukkan dengan Persamaan (1) (Cao et al., 2017).

$$y = f(x) = \frac{1}{1+e^{-\sigma x}} \quad (1)$$

## 2.5. Normalisasi Data

Normalisasi adalah proses penskalaan nilai atribut dari data sehingga bisa jatuh pada *range* tertentu (Mustaffa & Yusof, 2015). Proses normalisasi dilakukan karena perhitungan yang digunakan menghasilkan *output* dengan *range* data antara 0 dan 1. Proses normalisasi data ditunjukkan pada Persamaan (2).

$$X' = \frac{(X - X_{min})}{(X_{max} - X_{min})} \quad (2)$$

Keterangan:

$X'$  = Data hasil normalisasi

$X$  = Data asli

$X_{max}$  = Nilai maksimum data asli

$X_{min}$  = Nilai minimum data asli

## 2.6. Denormalisasi Data

Data hasil normalisasi kemudian dilakukan denormalisasi. Denormalisasi data adalah proses untuk mengembalikan nilai data menjadi nilai semula atau nilai yang sebenarnya berdasarkan hasil peramalan yang akan dilakukan. Proses perhitungan denormalisasi data ditunjukkan pada Persamaan (3).

$$X = (X'(X_{max} - X_{min})) + X_{min} \quad (3)$$

Keterangan:

$X'$  = Data hasil normalisasi

$X$  = Data asli


$X_{max}$  = Nilai maksimum data asli

$X_{min}$  = Nilai minimum data asli

## 2.7. Extreme Learning Machine

Metode *Extreme Learning Machine* (ELM) adalah metode pembelajaran yang termasuk dalam Jaringan Saraf Tiruan (JST). *Extreme Learning Machine* adalah Jaringan Saraf Tiruan *feedforward* sederhana dengan menggunakan satu lapisan tersembunyi (*hidden layer*) yang lebih dikenal sebagai *Single Hidden Layer Feedforward Neural Networks* (SLFNs) (Huang, 2006). Secara umum model JST pada metode ELM sebagai metode pembelajaran

dapat dilihat pada Gambar 2 (Huang, 2004).



Gambar 2. Struktur ELM

### 2.7.1. Proses Training

Tujuan dari proses *training* adalah mendapatkan *output weight* dengan tingkat kesalahan yang rendah. Proses perhitungan yang perlu dilakukan dalam proses *training* pada metode ELM adalah (Huang, 2004).

1. Melakukan inisialisasi *input weight* dan bias dengan bilangan acak yang kecil dengan *range* 0 sampai dengan 1 (Liang, 2006).
2. Menghitung nilai *output* pada *hidden layer* ditunjukkan pada Persamaan (4).

$$H_{init\ ij} = \left( \sum_{i=1}^n x_j w_i^T \right) + b_j \quad (4)$$

Keterangan:

$H_{init}$  : Matriks keluaran *hidden layer*.

$i$  : Jumlah data.

$j$  : Jumlah *hidden neuron*.

$w^T$  : Bobot *input transpose*

$x$  : *Input* data

$b$  : Bias

3. Menghitung semua nilai keluaran pada *hidden layer* dengan menggunakan fungsi aktivasi pada Persamaan (1). Perhitungan dengan fungsi aktivasi ditunjukkan pada Persamaan (5).

$$H(x) = \frac{1}{1 + e^{-x}} \quad (5)$$

Keterangan:

$H(x)$  : Matriks *output hidden layer*

$x$  : *Input*

4. Menghitung Matriks *Moore-Penrose Generalized Inverse*. Matriks ini didapatkan dari perkalian matriks *transpose* dari hasil *output hidden layer* dengan fungsi aktivasi. Perhitungan matriks *Moore-Penrose Generalized Inverse* ditunjukkan pada Persamaan (6).

$$H^+ = (H(x)^T \cdot H(x))^{-1} H(x)^T \quad (6)$$

Keterangan:

$H^+$  : Matriks *Moore-Penrose Generalized Inverse*

- $H(x)$  : Matriks *output hidden layer*
5. Menghitung *output weight* dari *hidden layer* ke *output layer*. Sebelum menghitung *output weight*, terlebih dahulu menghitung matriks *Moore- Penrose Generalized Inverse* dari hasil keluaran *hidden layer* dengan fungsi aktivasi. Kemudian dihitung *output weight* yang ditunjukkan pada Persamaan (7).

$$\beta = H^+T \quad (7)$$

Keterangan:

$\beta$  : Matriks *output weight*

$H^+$  : Matriks *Moore-Penrose Generalized Inverse*

$T$  : Matriks Target

6. Menghitung *Output*. *Ouput* peramalan diperoleh melalui perkalian matriks *output hidden layer* dengan matriks *output weight* ditunjukkan pada Persamaan (8).

$$O = H(x)\beta \quad (8)$$

Keterangan:

$O$  : *Output* Peramalan

$H(x)$  : Matriks keluaran *hidden layer*

$\beta$  : Matriks *output weight*

### 2.7.2. Proses Testing

Pada proses *testing* dilakukan dengan berdasarkan *input weight*, bias, dan *output weight* yang sesuai dengan hasil perhitungan *training*. Proses *training* (pembelajaran) bertujuan untuk mengembangkan model dari *Extreme Learning Machine* (ELM), sedangkan proses *testing* (pengujian) bertujuan untuk melakukan evaluasi kemampuan dari *Extreme Learning Machine* (ELM) sebagai metode untuk melakukan peramalan. Berikut adalah langkah-langkah dari proses *testing* (Huang, 2004).

1. Menggunakan *input weight* dan bias yang telah dihitung pada proses *training*
2. Melakukan perhitungan semua nilai *output* pada *hidden layer* dengan menggunakan Persamaan (4) dan dengan fungsi aktivasi ( $H(x)$ ) pada Persamaan (5).
3. Menggunakan hasil perhitungan proses *training* yaitu *output weight* dari *hidden layer* ke *output layer*. Melakukan perhitungan nilai keluaran di *output layer* yang merupakan nilai keluaran (*output*) hasil prediksi yang ditunjukkan pada Persamaan 9.

$$y = H(x)\beta \quad (9)$$

Keterangan:

$y$  : Matriks hasil peramalan

$\beta$  : Matriks *output weight*

$H(x)$  : Matriks keluaran *hidden layer* dengan fungsi aktivasi

### 2.8. Mean Absolute Percentage Error (MAPE)

Mape merupakan proses evaluasi kinerja suatu peramalan dengan menghitung nilai *error*. proses evaluasi nilai *error* dengan cara menghitung selisih antara nilai ramalan dengan nilai aktual yang selanjutnya diabsolutkan dan lalu diubah dalam bentuk presentase terhadap data asli (Darmayanti, Setiawan & Bachtiar, 2018). Menghitung nilai MAPE dapat dilihat pada Persamaan 10.

$$MAPE = \frac{1}{n} \sum_{i=1}^n \left| \frac{y_{i,pred} - y_{i,act}}{y_{i,act}} \right| \times 100 \quad (10)$$

Keterangan:

$y_{i,pred}$  = Nilai data hasil peramalan ke- $i$

$y_{i,act}$  = Nilai data aktual ke- $i$

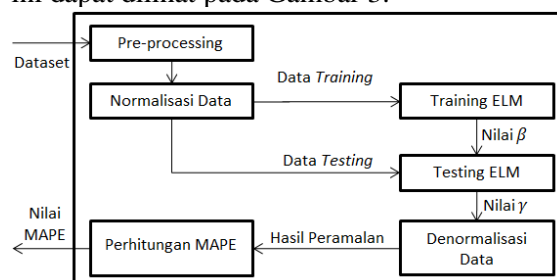
$n$  = Banyaknya data *testing*

$i$  = Indeks data

## 3. METODOLOGI

### 3.1. Strategi Penelitian

Diagram metode ELM dalam penelelitian ini dapat dilihat pada Gambar 3.



Gambar 3. Diagram Peramalan Curah Hujan dengan Metode ELM

Peramalan curah hujan dilakukan dengan metode *Extreme Learning machine* (ELM). Data yang digunakan adalah data hasil observasi Badan Meteorologi Klimatologi dan Geofisika (BMKG) stasiun klimatologi Karangploso Malang pada daerah Poncokusumo. Data yang digunakan pada penelitian ini adalah data curah hujan dalam bentuk *time series* dan dalam dasarian (10 hari).

Data pada penelitian ini akan dibagi menjadi beberapa fitur dan target, setelah itu dilakukan normalisasi data. Data kemudian



dibagi menjadi data *training* dan data *testing* untuk proses *training* dan *testing* pada algoritme ELM. Proses *training* akan menghasilkan nilai *output weight* ( $\beta$ ) yang akan digunakan pada proses *testing*. Pada proses *testing* menghasilkan nilai peramalan curah hujan ( $\gamma$ ). Hasil dari proses *testing* selanjutnya dilakukan denormalisasi mengembalikan data ke dalam bentuk sebelum normalisasi. Data hasil peramalan kemudian dilakukan proses perhitungan *Mean Absolute Percentage Error* (MAPE) untuk mengetahui kemampuan algoritme ELM dalam peramalan curah hujan melalui nilai selisih *error* dari data hasil peramalan dan data aktual.


### 3.2. Teknik pengumpulan Data

Pengumpulan data diperoleh dari Badan Meteorologi Klimatologi dan Geofisika (BMKG) di Karang Ploso Malang. Data yang akan digunakan adalah data curah hujan dasarian (kumpulan data selama 10 hari) dengan menggunakan data curah hujan di wilayah Poncokusumo dengan rentang tahun 2001 – 2014 pada dasarian ke-2 bulan Januari.

## 4. HASIL PEMBAHASAN

### 4.1 Pengujian Perbandingan Persentase Jumlah Data Training

Nilai parameter untuk banyak fitur sebesar 4 dan banyak *neuron* pada bagian *hidden layer* yaitu sebesar 2.




Gambar 4. Grafik Pengujian Perbandingan Persentase Jumlah Data Training

Dapat dilihat bahwa nilai dari rata-rata MAPE terkecil terlihat pada persentase sebesar 80% dengan nilai sebesar 6,9478% sedangkan nilai rata-rata MAPE terbesar pada persentase 50% dengan nilai 35,4518%. Melalui pengujian tersebut disimpulkan bahwa persentase data *training* berpengaruh pada nilai rata-rata MAPE. Semakin besar data *training* maka nilai rata-rata MAPE semakin kecil sebaliknya semakin kecil data *training* terjadi kenaikan

nilai rata-rata MAPE. Hal ini terjadi karena semakin banyak proses pembelajaran dengan menggunakan data *training* maka pengetahuan pembelajaran algoritme juga semakin baik, sebaliknya semakin sedikit menyebabkan algoritme kurang mampu mempelajari data yang diujikan dengan pengetahuan pembelajaran sedikit.

### 4.2 Pengujian Jumlah Variabel Lag Time (Fitur)

Setiap parameter nilai yang diuji akan dilakukan 10 percobaan dengan nilai parameter yang tetap untuk persentase data *training* bernilai 80% dan banyak *neuron* pada bagian *hidden layer* yaitu sebesar 2.




Gambar 5. Grafik Pengujian Jumlah Variabel Lag Time (Fitur)

Dapat diperhatikan bahwa jumlah fitur sebanyak 4 menghasilkan nilai dari rata-rata MAPE yang terkecil dengan nilai 6,7568%. Nilai dengan rata-rata MAPE terbesar ada pada jumlah fitur sebanyak 2 dengan nilai 41,7843%. Berdasarkan pengujian tersebut dapat diperhatikan bahwa nilai rata-rata MAPE pada fitur sebanyak 2 memiliki nilai paling besar karena proses pembelajaran yang kurang dari jumlah fitur yang digunakan. Pada jumlah fitur 4 sampai 10 terjadi kenaikan karena perbedaan data *time series* (terdapat perbedaan 2 digit pada data curah hujan) yang digunakan dan data yang digunakan hanya berjumlah 14 tahun (hanya 14 data *time series* curah hujan). Hal tersebut membuktikan bahwa pengujian banyak variabel *lag time* (fitur) dapat memengaruhi nilai rata-rata MAPE.

### 4.3 Pengujian Jumlah Neuron pada Hidden Layer

Nilai parameter persentase data *training* bernilai 80 dan fitur sebanyak 2.



Rata-rata MAPE terkecil terletak pada jumlah *neuron* sebanyak 2 dengan nilai sebesar 6,0331% dan nilai rata-rata MAPE terbesar adalah sebanyak 10 *neuron* dengan nilai sebesar 29,7614%. Hal tersebut disebabkan karena semakin besar jumlah *neuron* pada *hidden layer* maka dapat meningkatkan hasil ketepatan nilai peramalan mendekati nilai aktual, tetapi jumlah *neuron* yang semakin besar juga membuat ruang variabel *lag time* (fitur) yang terbentuk semakin besar sehingga membuat pencarian ruang fitur semakin luas sehingga membuat terjadi kenaikan rata-rata MAPE pada jumlah *neuron*. Hal ini juga membuktikan bahwa diperlukan pengujian parameter yang optimal (optimasi) jumlah *neuron* pada *hidden layer* yang semakin besar tidak selalu akan menghasilkan tingkat kesalahan semakin yang kecil.

## 5. KESIMPULAN

Hasil untuk kesimpulan pada penelitian ini sebagai berikut:

1. Melalui hasil pengujian diperoleh rata-rata MAPE terkecil pada pengujian banyak variabel *lag time* (fitur) menghasilkan nilai sebanyak 4 fitur dengan nilai rata-rata MAPE sebesar 6,7568%. Pada pengujian persentase banyak data *training* menghasilkan nilai rata-rata MAPE sebesar 6,9478% dengan menggunakan perbandingan data *training* sebesar 80%. Pada pengujian jumlah *neuron* pada *hidden layer* menghasilkan rata-rata MAPE sebesar 6,0331% dengan menggunakan 2 *neuron* pada *hidden layer*. Melalui hasil nilai rata-rata MAPE pada masing-masing pengujian dapat disimpulkan bahwa pengujian variabel *lag time* (fitur), pengujian perbandingan data *training* dan data *testing* serta pengujian *neuron* pada *hidden layer* berpengaruh dalam peramalan curah hujan.
2. Melalui hasil pengujian yang telah dilakukan menghasilkan nilai *error rate* terkecil sebesar 3,6852% dengan

menggunakan 2 *neuron* pada *hidden layer*. Parameter yang digunakan pada pengujian peramalan curah hujan menggunakan metode *Extreme Learning Machine* (ELM) yaitu perbandingan data *training* yaitu sebesar 80%, nilai variabel *lag time* (fitur) sebanyak 4 fitur dan *neuron* yang digunakan pada *hidden layer* yaitu sebanyak 2 *neuron*.

## 6. DAFTAR REFERENSI

- Agustina, Irwin D., Anggraeni, W., & Mukhlason, A., 2009. Penerapan Metode Extremem Learning Machine Untuk Peramalan Permintaan. Surabaya : Institut Teknologi Sepuluh November.
- BMKG, 2015. *Analisis Hujan November 2015 dan Prakiraan Hujan Januari-Maret 2016*. Malang: Stasiun Klimatologi Karangploso.
- Cao, W., Gao, J., Ming, Z. & Cai, S., 2017. Some Tricks in Parameter Selection for Extreme Learning Machine.
- Cao, J., & Xiong, L., 2014. Protein Sequence Classification with Improved Extreme Learning Machine Algorithms. China.
- Chai, T., & Draxler, R., R., 2014. Root mean square error (RMSE) or mean absolute error (MAE)? – Arguments against avolding RMSE in the literature. *Geosci. Model Dev.* ,1247-1250.
- Ertuğrul, Ö.F. & Kaya, Y., 2014. A Detailed Analysis on Extreme Learning Machine and Novel Approaches Based on ELM. *American Journal of Computer Science and Engineering*, [online] 1(5), pp.43–50.
- Fardani, D., P., 2015. Sistem Pendukung Keputusan Peramalan Jumlah Kunjungan Pasien Menggunakan Metode Extreme learning Machine (Studi Kasus : Poli Gigi RSUD Wahidin Sudiro Husodo Mojokerto). Vol. 1, no. 1, April 2015. Universitas Airlangga.
- Jimoh, R., G., Olagunju, M., Folorunso, I., O., & Asiribo, M., A., 2013. *Modeling Rainfall Prediction using Fuzzy Logic*. International Journal of Innovative Research in Computer and

- Communication Engineering, 2320 - 9798.
- Huang, G., B., Zhu, Q., Y., & Siew, C., K., 2006. *Extreme Learning Machine : A New Learning Scheme of Feedforward Neural Networks*. Elsevier science : Neurocomputing.
- Khotimah, Bain K., Sari, Eka Mala R., & Yulianarta, H., 2010. Kinerja Metode Extreme Learning Machine (ELM) Pada Sistem Peramalan. *Journal Simantec*, Vol 1, p.186.
- Kusumastuti, D. I. & Sulistiowati., 2015. *Analisa Karakteristik Curah Hujan dan Kurva Intensitas Durasi Frekuensi (IDF) di Provinsi Lampung*. Rekayasa, Volume 14.
- Liang, N., Y., Huang, G., B., Saratchandran, P., & Sundararajan, N., 2006. A Fast and Accurate Online Sequential Learning Algorithm for Feedforward networks. *IEEE Transactions On Neural Networks*, Vol 17(6), p.1411-1423.
- Nhita, F., A., Wisesty, U. N. & Ummah, I., 2015. *Planting Calender Forecasting System Using Evolving Neural Network*. *Far East Journal of Electronics and Communications*, Volume 14, pp. 81-92.
- Ogi., 2011. Analisis Variabilitas Curah Hujan Dan Suhu Di Bali. *2016 1st International Conference on Information Technology, Information Systems and Electrical Engineering*.
- Patro, S.G.K., & Sahu, K.K., 2015. *Normalization : A Preprocessing Stage*. Department of CSE & IT, VSSUT, Burla, Odisha, India.
- Rani, K., B., & Govardhan, A., 2013. *Rainfall Prediction using Data Mining Techniques – A Survey*. Department of Computer Science & Engineering, 3903.
- Sun, Z., L., Chai, T., M., Au, K., F., & Yu, Y., 2008. Sales Forecasting Using Extreme Learning Machine With Application In Fashion Retailing. *Elsevier Decision Support Systems* 46 (2008) 411-419.
- Shamshirband, S., Mohammadi, K., Tog, C., W., Petkovic, D., Porcu, E., Mostafaeipour, A., Ch, S., & Sedaghat, A., 2015. Application of extreme learning machine for estimation of wind speed distribution. Springer-Verlag Berlin Heidelberg.
- Toth, E., Brath, A., & Montanari, A., 2000. *Comparison of Short-Term Rainfall Prediction Models for Real-Time Flood Forecasting*. *Journal of Hydrology*, 132 – 147.